Документација за проект

Анализа и предвидување на квалитет на воздух

Петар Гоговски, Јана Стоичкова

28-ми Октомври, 2026

Вовед

Целта на проектот е да се испита загадувањето со честичките PM2.5 и PM10 на повеќе мерни станици во Скопје. За таа цел ги комбинираме дневните мерења на квалитетот на воздухот со метеоролошки податоци. Главното истражувачко прашање е како се менуваат концентрациите на PM2.5 и PM10 помеѓу станиците и низ времето, како и кои метеоролошки и други загадувачки променливи се поврзани со нив. Дополнително, проверивме дали може да се предвидат нивоата на загадување, да се класифицираат деновите со високо загадување и да се откријат групи денови со слични карактеристики. Во текот на работата повеќе пати ги подобрувавме анализите, па документацијата го следи тој процес и ги прикажува главните резултати.

1. Собирање на податоци

Дневните податоци за квалитетот на воздухот ги презедовме од OpenAQ, а метеоролошките податоци од Open-Meteo. Податоците за загадувањето ги вклучуваат PM2.5, PM10 и гасови како NO, NO2, O3, SO2 и CO. Метеоролошките променливи опфаќаат температура, влажност, ветер, сончево зрачење, температура и влажност на почвата, врнежи и воздушен притисок. Податоците за Скопје го покриваат периодот од 11.12.2016 до 31.12.2025. При собирањето проверивме дали сите датотеки од OpenAQ ги користат единиците μg/m³ и сите ја поминаа проверката.

2. Опис на податоците

Главната табела е организирана според мерна станица и датум. Секој ред претставува една станица во еден ден. Почетната табела има 12.271 ред и 75 колони.

Променливите се поделени во неколку групи:

- Идентификатори: station_id, station_name и date.
- Целни променливи: pm25 и pm10, односно дневните просечни концентрации, како и други загадувачи NO, NO2, O3, SO2 и CO кои можат да служат како predictors.
- Покриеност на мерењата: за секој загадувач се бележи бројот на валидни часовни мерења во текот на денот.
- Метеоролошки променливи: различни мерења за температура, релативна влажност, dew point, притисок, врнежи, снежна покривка, облачност, зрачење, брзина и насока на ветер, evapotranspiration, vapour pressure deficit и влажност/температура на почвата.
- Календарски променливи: месец, година, ден во неделата, викенд и сезона.

Само PM2.5 и PM10 ги третираме како target variables. Останатите загадувачи и метеоролошките променливи ги користиме како можни explanatory features.

3. Претпроцесирање

Часовните мерења ги претворивме во дневни просеци. Денот го сметавме за валиден за одреден загадувач само ако имаше доволно часовни мерења, во спротивно, вредноста ја оставивме како missing, без да ја пополнуваме. Проверивме и дупликати според (station_id, date), за секоја станица да има најмногу еден запис за секој датум. Потоа ги пресметавме summary statistics и ги проверивме распределбите и екстремните вредности.

Бидејќи PM2.5 има помала покриеност од PM10, применивме strict missing-data policy и complete-case deletion, без imputation. Целните вредности не ги пополнувавме, бидејќи така би создале вештачки податоци за вредностите што треба да ги предвидуваме. Исто така, за секој загадувач задржавме само станици со најмалку 365 валидни денови и најмалку две години со по 90 или повеќе валидни денови. Така ги исклучивме Ректорат за PM2.5, бидејќи нема мерења за овој загадувач, и Миладиновци за PM10, бидејќи има само 93 валидни денови. На крај останаа по 5 станици за секој загадувач, со 3.990 денови за PM2.5 и 8.798 за PM10.

Откако ги завршивме проверките и изборот на податоци, исчистената дневна табела, заедно со дополнителната ознака за квалитет на мерењата, ја зачувавме во Parquet формат. Оваа датотека потоа ја користевме како главен извор на податоци за сите понатамошни анализи и модели.

4. Проблеми со кои се соочивме

Еден од проблемите беше физичката неусогласеност помеѓу PM10 и PM2.5. Бидејќи PM10 ги вклучува и честичките од фракцијата PM2.5, вообичаено PM10 треба да биде поголем или еднаков на PM2.5. Сепак, од 3.445 денови со валидни мерења за двата загадувачи, во 171 случај (околу 5%) PM10 беше помал од PM2.5. Повеќето разлики беа мали и може да се должат на шум од различните сензори, но 34 случаи имаа разлика поголема од 10 μg/m³, а најголемата достигна 94,5 μg/m³. Овие случаи најчесто се појавуваа на станиците Карпош и Центар.

За да провериме дали причината е недоволна покриеност, ги анализиравме часовните мерења за тие 34 случаи. Просекот беше околу 23,2 од 24 часа, слично како кај другите валидни мерења. Бидејќи не можевме со сигурност да утврдиме кој сензор дал погрешна вредност, не ги бришевме и не ги коригиравме податоците. Наместо тоа, додадовме boolean quality flag, large_pm10_lt_pm25_flag, за да ги означиме сомнителните редови и подоцна да провериме дали влијаат врз резултатите. Забележавме и еден изолиран случај со PM10 = 0.0 и валиден PM2.5, кој може да укажува на дефект на сензорот. Не ја користевме променливата pm_violation_diff = pm25 - pm10 како feature, бидејќи би можела да создаде circular correlation со целните вредности.

Друг проблем беше визуелизацијата на корелациите. Heatmap со сите нумерички колони беше премногу густа и тешка за читање, бидејќи многу метеоролошки променливи се меѓусебно поврзани. Затоа додадовме посебна анализа со променливите што имаат најголема апсолутна корелација со PM2.5 и PM10, покомпактна heatmap со top 20 features и LOWESS scatterplots за шесте најважни променливи. Во една рана месечна споредба, CO имаше значително поголеми вредности од другите загадувачи, па заедничкиот графикон беше погрешно претставен. За вакви споредби потребни се посебни оски, subplots или нормализација.

Имавме и проблем со нерамномерната покриеност низ станиците и времето. Некои станици почнале да мерат PM2.5 дури во 2023 година, Ректорат престанал со мерења во август 2024, а Миладиновци има многу малку PM10 податоци. Затоа не ги пополнувавме празнините, туку применивме јасни правила за избор на станици и проверувавме колку редови остануваат по секоја фаза. На пример, од 3.990 избрани редови за PM2.5, останаа 1.888 за моделирање откако беа потребни реални податоци за lag и rolling features.

5. Користени методи

Во EDA користевме summary statistics и tail percentiles, бидејќи концентрациите имаат right-skewed распределба и просекот сам по себе не е доволен. Користевме histograms со KDE, boxplots по станица, time-series графикони со месечни просеци и 30-day rolling average, како и scatterplots за споредба на PM2.5, PM10 и другите променливи. Pearson correlation ја користевме како брза проверка на линеарната поврзаност.

За feature engineering, првин ги подредивме податоците за секоја станица хронолошки и потоа пресметавме lag и rolling features. Така празните денови не се прескокнуваат незабележано. Додадовме autoregressive lags за 1, 2 и 3 дена и rolling mean/std за 3 и 7 дена. Со shift(1) спречивме моделот да ја користи вредноста од денот што треба да го предвиди. Додадовме и cyclical encodings за месец и ден во неделата со sine/cosine, како и binary label за високо загадување: над 25 μg/m³ за PM2.5 и над 50 μg/m³ за PM10.

За regression forecasting споредивме Linear Regression, Random Forest, Gradient Boosting, Lasso, Ridge и Decision Tree со persistence baseline, каде денешната вредност се предвидува со вчерашната. Податоците ги поделивме хронолошки: првите 80% од датумите за training, а последните 20% за testing. Така избегнавме идните податоци да протечат во training. Тестиравме две опции за времето: same-day, кога моделот ги добива временските услови од истиот ден и резултатот е nowcast, и t-1, кога користи само вчерашни временски податоци за вистинско предвидување. Користевме permutation importance и ги групиравме features според тип, како lags, rolling, temperature и radiation. Дополнително проверивме дали корелациите со времето остануваат во рамките на иста сезона и повторно ги пресметавме резултатите без означените неусогласени мерења.

За classification, деновите ги поделивме на две класи: високо загадување и останати денови. Ги споредивме Logistic Regression, Random Forest, Gradient Boosting, Naive Bayes,

KNN и Decision Tree со majority-class baseline. Наместо да се потпираме само на accuracy, ги следевме precision, recall, F1 и ROC-AUC. Ги користевме истите временски режими, permutation importance и проверка со отстранување на означените редови.

За clustering првично ги групиравме деновите по станица со 21 feature. Ги скалиравме континуираните променливи со RobustScaler и користевме PCA што задржува 90% од variance. Ги споредивме KMeans, Gaussian Mixture Model (GMM) и DBSCAN, а подоцна додадовме hierarchical clustering и bootstrap stability check. Првата верзија најде зимска група со високо загадување. Сепак, потоа ја преработивме анализата: наместо посебни редови за секоја станица, користевме дневни просеци од сите станици и 10 features поврзани главно со времето. Правилото за избор на k го дефиниравме однапред: да го избереме најмалото k кај кое групата со највисоко загадување има најмалку 60% зимски денови. Доколку тоа не се случи, да го користиме k со најдобар silhouette score. За DBSCAN користевме k-distance curves и grid search за eps и min_samples. Исто така, насоката на ветерот ја претворивме во u/v components пред пресметување просек, бидејќи директното просечување на степени може да даде погрешен резултат.

6. Exploratory Data Analysis

PM2.5 и PM10 имаат right-skewed распределба, со многу денови со пониско загадување и мал број денови со многу високи вредности. PM2.5 има просек 24,4, медијана 17,9 и максимум 253,7 μg/m³. PM10 има просек 48,7, медијана 36,7 и максимум 435,7 μg/m³. Бидејќи просекот е под влијание на екстремните вредности, медијаните и percentiles подобро ја опишуваат типичната состојба.

Загадувањето се разликува и по станица. Центар и Карпош имаат највисоки типични PM2.5 вредности, со медијани 21,2 и 19,3. За PM10 највисоки медијани имаат Ректорат и Центар, 41,6 и 38,2. Миладиновци генерално има најниско загадување за двата показатели.

Највисоките вредности се забележуваат во декември и јануари, со месечни просеци околу 44 μg/m³ за PM2.5 и 83–89 μg/m³ за PM10. Најниско загадување има генерално од април до септември. Овој образец се повторува низ годините. Греењето, температурните инверзии и послабото разнесување на загадувачите може да придонесуваат за зимските вредности, но EDA покажува поврзаност, а не докажува причинска врска.

PM2.5 и PM10 имаат силна позитивна корелација (r = 0,815). CO и NO се меѓу најсилно поврзаните променливи: CO има корелација околу 0,51 со PM2.5 и 0,62 со PM10, а NO околу 0,47 со двата. Ова може да биде поврзано со заеднички извори како согорување и сообраќај. Температурата има негативна корелација со загадувањето, приближно -0,42 за температурата на воздухот и -0,48 до -0,49 за плитките слоеви на почвата. Слична негативна поврзаност имаат radiation и evapotranspiration. O3 е умерено негативно поврзан, а SO2 има слаба позитивна корелација. По претворањето на насоката на ветерот

во u/v components, компонентата север-југ покажува умерена позитивна корелација, додека брзината на ветерот има слаба негативна корелација.

Најперспективни групи features се идентитетот на станицата, календарот/сезоната и одредени загадувачи и температурни променливи, како CO, NO и температурата. Ветерот, влажноста и зрачењето имаат послаба линеарна корелација, но сепак може да бидат корисни за nonlinear модели.

7. Регресија

Во првата верзија, Linear Regression беше најдобар за PM2.5 со RMSE 13,62, MAE 8,93 и R^2 0,734. Го надмина persistence baseline, додека Random Forest и Gradient Boosting имаа послаби резултати. Ова покажа дека посложените модели не секогаш се подобри и дека едноставниот линеарен модел полесно ја фаќа главната поврзаност.

Во тековната верзија, со хронолошка 80/20 поделба, останаа 1.888 редови за PM2.5 и 3.575 за PM10. При користење на same-day weather, Linear Regression беше најдобар за PM2.5 (RMSE 13,20, MAE 8,67, R^2 0,751), околу 9,7% подобар од persistence. За PM10 најдобар беше Random Forest (RMSE 14,16, MAE 8,62, R^2 0,809), околу 6,6% подобар од baseline.

При вистинско предвидување со временски податоци од претходниот ден (t-1), резултатите се послаби. Најдобар за PM2.5 е Lasso со RMSE 14,17, што е само 3,1% подобро од persistence. За PM10 најдобар е Ridge со RMSE 14,93, односно 1,5% подобро. Ова покажува дека голем дел од подобрувањето со weather features доаѓа од тоа што моделот веќе ги знае временските услови за денот што го предвидува.

Permutation importance покажа различни резултати за двата загадувачи. Кај PM2.5, моделот најмногу се потпира на cloud, radiation и temperature features. Кај PM10, најважна е вредноста на загадувањето од претходниот ден. Проверка во рамките на иста сезона покажа дека корелацијата помеѓу температурата и загадувањето е многу послаба отколку кога се гледаат сите сезони заедно. Тоа значи дека времето често служи како показател за сезоната, наместо да го објаснува дневното менување на загадувањето. Отстранувањето на означените неусогласени редови речиси не ги промени резултатите.

8. Класификација

Во првата верзија, majority-class baseline имаше 68,1% accuracy, главно поради тоа што околу 34% од деновите беа означени како денови со високо PM2.5. Random Forest беше најдобар со accuracy 0,893, precision 0,768, recall 0,951, F1 0,850 и ROC-AUC 0,965.

Во финалната верзија, за PM2.5 над 25 μg/m³, Random Forest постигна accuracy 0,885, precision 0,747, recall 0,967, F1 0,843 и AUC 0,969. За PM10 над 50 μg/m³, Random Forest

повторно беше најдобар со accuracy 0,927, precision 0,768, recall 0,807, F1 0,787 и AUC 0,964. Во двата случаи ги надмина останатите модели и majority baseline.

Високиот recall за PM2.5 е важен ако моделот се користи за предупредување, бидејќи пропуштањето вистински ден со високо загадување може да биде посериозно од лажно предупредување. Кај PM10 задачата е потешка, делумно затоа што тест периодот содржи помал процент денови со високо загадување. Кога користевме само временски податоци од претходниот ден, F1 малку се намали: од 0,843 на 0,829 за PM2.5 и од 0,787 на 0,767 за PM10.

Permutation importance покажа дека најважен feature за двата загадувачи е вредноста од претходниот ден (lag-1). Кај PM10, следни по важност се rolling pollution values, а кај PM2.5 се features поврзани со ветерот. Отстранувањето на редовите со неусогласени PM мерења немаше значајно влијание врз резултатите.

9. Кластерирање

Во првата верзија на clustering, со PM2.5 и 21 feature, KMeans со k=4 пронајде посебна зимска група со високо загадување. Таа содржеше 358 денови со просечен PM2.5 од 50,9 μg/m³, а 81% од нив беа зимски денови. Сличен образец се појави и кај PM10, каде зимската група имаше 418 денови со просечен PM10 од 105,2 μg/m³. Во таа фаза заклучивме дека clustering ги потврдува сезонските обрасци од EDA.

Подоцна ја променивме анализата така што секој ред претставува дневен просек од сите станици, а користевме 10 features главно поврзани со времето. Со оваа верзија резултатите се разликуваа.

За PM2.5, правилото за зимска група не беше исполнето за ниту едно k од 2 до 8, па го избравме k=2 според silhouette score. Но, оваа поделба не ги одвојуваше нивоата на загадување, туку дождливите денови од сувите. Сите методи го покажаа сличниот образец. Иако silhouette scores беа високи, тие ја мерат јасната разлика меѓу дождливи и суви денови, а не посебен режим на загадување. Bootstrap stability на KMeans беше висока (ARI 0,951 ± 0,065), што значи дека поделбата е стабилна, но не е поделбата што ја баравме.

Кај PM10, правилото за зимска група беше исполнето при k=5. KMeans пронајде група од 330 денови со просечен PM10 од 116,6 μg/m³, температура од 4,6°C и притисок од 1023 hPa. Од нив 74% беа зимски денови и немаше летни денови. Hierarchical clustering пронајде слична група од 225 денови со просек 133,8 μg/m³, од кои 83% беа во зима. GMM пронајде поширока група со поумерени вредности. Bootstrap stability беше висока (ARI 0,905 ± 0,044). DBSCAN, за разлика од другите методи, главно ги раздели дождливите од сувите денови.

Разликата помеѓу двете верзии на PM2.5 clustering доаѓа од промената на редовите и features. Првата верзија имаше lag, rolling и календарски features, додека новата користи дневни просеци и само временски променливи. Затоа, во тековната верзија, PM2.5 не покажува јасна зимска група, туку главно разлика помеѓу дождливи и суви денови. Кај PM10, зимскиот режим на високо загадување останува видлив и со временските променливи. Резултатите од clustering ги зачувавме во Parquet датотеки со labels за секој ден и summary табели за групите.

10. Заклучок

Резултатите покажуваат дека загадувањето во Скопје има силен сезонски образец, особено во декември и јануари. CO и NO се позитивно поврзани со PM2.5 и PM10, додека температурата на воздухот и почвата има негативна поврзаност. Околу 34% од деновите што се користеа за моделирање го надминуваат прагот од 25 μg/m³ за PM2.5, а околу 30% го надминуваат прагот од 50 μg/m³ за PM10.

Кај forecasting нема еден модел што е најдобар за сè. Linear Regression има најдобри резултати за PM2.5 со RMSE 13,20 и R^2 0,751, додека Random Forest е најдобар за PM10 со RMSE 14,16 и R^2 0,809. Кога моделите користат само временски податоци од претходниот ден, подобрувањето во однос на persistence е многу помало, од 1,5% до 3,1%. Ова покажува дека дел од привидната корист од времето е поврзана со сезонските промени.

За класификација на денови со високо загадување, Random Forest е најдобар за двата загадувачи. За PM2.5 има accuracy од 88,5% и recall од 96,7%, а за PM10 accuracy од 92,7%. Најважен feature е нивото на загадување од претходниот ден. Тоа значи дека моделите главно ја користат неодамнешната состојба за да проценат какво ќе биде загадувањето следниот ден.

Clustering најјасно го потврдува постоењето на зимски режим со високо загадување кај PM10. KMeans и hierarchical clustering пронаоѓаат слични групи, а високите ARI вредности покажуваат дека резултатот е стабилен. Кај PM2.5, со тековниот избор на features, не се појавува јасна зимска група. Најголемата разлика е помеѓу дождливи и суви денови, но таа не ги разделува добро нивоата на загадување.

Генерално, резултатите покажуваат дека PM10 има повторлив зимски режим што би можел да биде важен за системи за рано предупредување и мерки за намалување на загадувањето. PM2.5, пак, во оваа поставеност е посоодветен за continuous forecasting отколку за откривање посебни режими. Овие резултати се корисни, но треба да се има предвид дека корелацијата не докажува причинско-последична врска и дека квалитетот на предвидувањата зависи од достапноста на податоците.